Upravljanje digitalnim dokumentima (UDD)

Kontrolna tačka, Zdravko Milinković E2-49/2023

1. Arhitektura sistema i High-Level pregled

Ovaj projekat predstavlja implementaciju sistema agencije koja služi za izdavanje zakona. Ključni procesi ovog sistema su:

- Registracija klijenata – tokom registracije, član vlade bira usluge koje želi da kupi od agencije. Pored toga, član vlade bira način pretplate, koji može biti mesečni ili godišnji, i način plaćanja.
- Kodifikacija zakona – proces izmene trenutnog zakona ili grupe zakona.
- Raskidanje ugovora – proces koji se automatski pokreće ukoliko je istekao rok od 5 dana za kodifikaciju zakona.

Kako bi korisničko iskustvo bilo pozitivno, na backendu aplikacije nalazi se modularni i plagabilni sistem za elektronsko plaćanje koji omogućava korisniku plaćanje usluga putem platne kartice, QR koda, PayPal-a i putem kriptovaluta. Poseban akcenat je stavljen na bezbednost ovog sistema i rukovanje novčanim sredstvima.

Implementacija sistema za efikasno skadištenje i pretraživanje digitalnih dokumenata, kao što su ugovori i zakoni, značajno doprinosi razvoju i performansama aplikacije, kao i poboljšanju korisničkog iskustva. Glavni akcenat sistema je brza i efikasna pretraga. Pregled arhitekture sistema za pretragu i upravljanje digitalnim dokumentima nalazi se na slici 1.

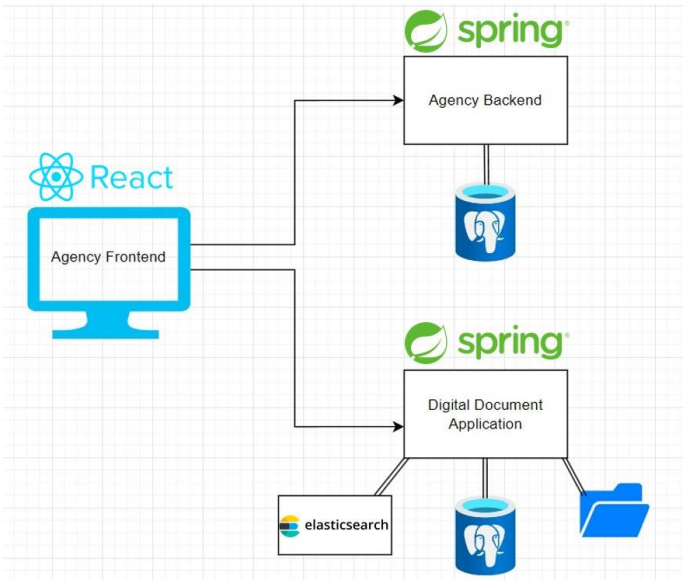

Slika 1. Prikaz arhitekture sistema

1.1 Arhiktetura sistema za pretragu i upravljanje digitalnim dokumentima

Sistem predstavlja nezavisnu web aplikacija koja se sastoji od dva glavna dela:

- Serverska strana – deo sistema implementiran u *Spring Boot* radnom okviru, koji je zasnovan na REST API principima i služi za obradu digitalnih dokumenata putem HTTP zahteva. Ovaj deo sistema predstavljen je kao troslojna aplikacija i sastoji se od:
    - Prezentacionog sloja – predstavlja sloj najbliži klijentskoj strani čija je uloga primanje zahteva i njihovo mapiranje na određene metode u sistemu.
    - Biznis sloja – predstavlja sloj u kojem se odvija sama logika aplikacije. Sva rukovanja entitetima, kao i potencijalni izuzeci dešavaju se u okviru ovog sloja. U ovom sloju nalaze se *Indexer*, koji vrši operacije dodavanja, modifikacije i brisanja nad dokumentima unutar indeksne strukture, kao i *ResultRetriver* koji vrši upite nad tim dokumentima.
    - Sloja podataka – predstavlja najniži sloj ove strukture. Glavna uloga ovog sloja pored rada sa entitetima je i obavljanje komunikacije sa relacionom bazom podataka i *ElasticSearch* skladištem.
- Klijentska strana – deo sistema zadužen za interakciju sa korisnicima. Putem ovog dela aplikacije, korisicima je omogućena registracija na sistem, kao i pretraga ugovora i zakona putem odgovarajućih formi i odabranih parametara. Takođe, korisnici imaju mogućnost otpremljivanja i preuzimanja svih ugovora i zakona. Klijentska strana razvijena je upotrebom *React.JS* biblioteke za *JavaScript*.

Za skladištenje entiteta koristi se PostgreSQL relaciona baza podataka. Digitalni dokumenti čuvaju se u pdf formatu na lokalnom računaru. Kako je neophodno podržati efikasnu i brzu pretragu, aplikacija se oslanja na rad *ElasticSearch* sistema i samim tim, deo podataka se skladišti u okviru indeksne strukture *ElasticSearch* sistema.

Radi lakše kolaboracije *Spring Boot* okruženja i *ElasticSearch* sistema koristi se paket *Spring Data ElasticSearch*. On omogućava razne prednosti kao što su:

- Jednostavna uspostava i održavanje komunikacije sa *ElasticSearch* serverom
- Anotaciju modela koristeći indekse strukture
- *ElasticSearchRestTemplate* – omogućava laku komunikaciju sa sistemom i olakšano kreiranje složenih upita.
- Generički repozitorijumi – interfejsi sa već generisanim skupovima upita.

1.2 Dijagram klasa

Prethodno je pomenuto kako je neophodno podržati efikasnu pretragu po određenim atributima. Kako bi ovo bilo moguće, deo podataka će se čuvati u relacionoj PostgreSQL bazi, dok će se drugi deo podataka skladištiti u okviru *ElasticSearch* sistema. Na slici 2. prikazan je klasni dijagram sistema.

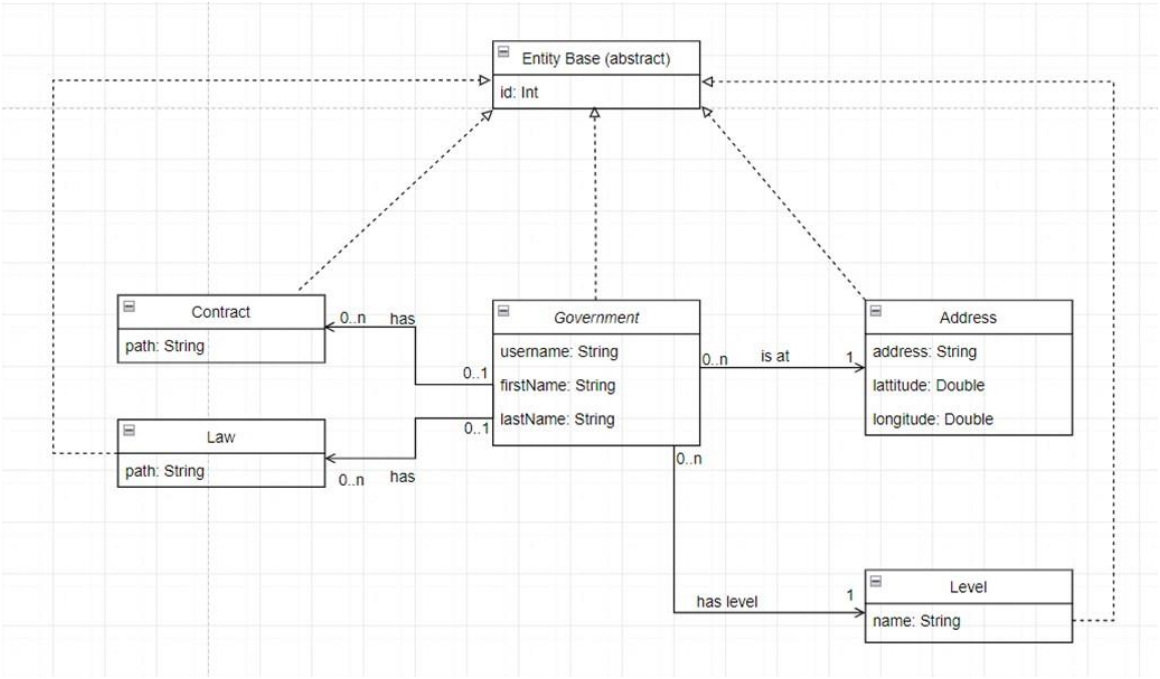

Slika 2. Klasni dijagram sistema

Razlikujemo sledeće klase:

- *Entity Base* - apstraktna klasa koja predstavlja bazu svih entita. U njoj se nalazi identifikaciona oznaka i svi entiteti sistema nasleđuju ovu klasu.
- *Contract* - klasa koja predstavlja ugovor i sastoji se od identifikacione oznake i atributa path koji ukazuje na njegovu lokaciju na lokalnom računaru.
- *Law* - klasa koja predstavlja zakon koja se takođe sastoji od identifikacione oznake i path atributa.
- *Government* - klasa koja predstavlja vladu i sastoji se od identifikacione oznake, atributa imena i prezime, kao i korisničkog imena. Vlada sadrži referencu klasa *Address* i *Level*, što znači da se vlada nalazi na tačno jednoj lokaciji i da ima tačno jedan nivo uprave.
- *Address* - klasa koja predstavlja lokaciju na kojoj se vlada nalazi. Pored identifikacione oznake sadrži adresu, kao i geografsku širinu i dužinu, za lakše predstavljanje na mapi.

- *Level* - klasa predstavlja nivo uprave vlade. Svaki nivo uprave sastoji se od svoje identifikacione oznake kao i naziva tog nivoa.

U zavisnosti od dalje implementacije zahteva projekta, sam model je sklon izmeni i dodavanju novih atributa ili izmeni hijerarhije klasa.

1.3 Indexing Units

Indeksnu strukturu koja se koristi u okviru *Elasticsearch*-a modeluje se JSON objektima. Indeksna struktura sastoji se imena polja i njihovih tipova podataka, koja se dobijaju mapiranjem. U listingu 1 prikazan je primer indeksne strukture ugovora koja omogućava pretragu po imenu i prezimenu zaposlenog koji je potpisnik ugovora, po nivou uprave, po nazivu, po lokaciji kao i po sadržaju dokumenta.

```
{
 "mappings":{
  "properties":{
     "governmentUsername":{
      "type": "text"
     },
     "governmentFirstName":{
      "type": "text",
      "analizer": "serbian"
     },
     " governmentLastName ":{
      "type": "text",
      "analizer": "serbian"
     },
      "governmentLevelId":{
      "type": "integer"
     },
      "governmentAddress":{
      "type": "geo_point"
     },
      "contractContent":{
      "type": "text",
      "analizer": "serbian"
     }
   }
  }
}
```

Listing 1. Indeksa struktura ugovora

2. Pretrage

U sistemu potrebno je implementirati:

- Pretraživanje ugovora po imenu i prezimenu zapolsenog koji je potpisnik ugovora
- Pretraživanje ugovora prema nazivu vlade i nivou uprave
- Pretraživanje dokumenata prema sadržaju ugovora
- Pretraživanje dokumenata prema sadržaju zakona
- Pretraživanje ugovora po geolokaciji vlade
- Pretraživanje kombinacijom prethodnih parametara

Kombinovano pretraživanje podrazumeva upotrebu *QueryBuilders* klase, koja nudi razne mogućnost za formiranje kompleksnih upita. Klasa *QueryBuilders* prevodi tj. mapira upit u odgovarajući *query*. Takođe, ova klasa podržava *BooleanQuery*, koji se dodaje pomoću *boolQuery* metode i omogućava logičko kombinovanje parametara koristeći standardne AND, OR i NOT operatore. Pretraga po frazama može se vršiti korišćenjem *MatchPhrazeQuery*-ja. Pretraga po geolokaciji vlade podrazumeva da korisnik zadaje ime grada ili adresu i radijus u okviru kojeg se vrši pretraga.

Za lepši prikaz rezultata potrebno je kreirati dinamički sažetak tj. *Highligher.* To se može učiniti korišćenjem klase *HighlighterBuilder* kojoj se dodaju polja za koja je potrebno kreirati kratak sažetak. Ovakvi složeni upiti mogu se vršiti nad *ElasticSearchRestTemplate*-om.

U sledećim listinzima biće prikazana implementacija nekih od prethodnih zahteva koristeći *ElasticSearch Data Repository*.

```
public interface ContractRepository extends ElasticsearchRepository<Contract, String> {
        List<Contract> getContractsByLevelIdOrAbove(int levelId)
}
```

Listing 2. Pretraga ugovora po određenom ili višem nivou vlade

```
public interface ContractRepository extends ElasticsearchRepository<Contract, String> {
        @Query("{\"bool\": {\"must\": [{\"match\": {\"contract.usename \": \"?0\"}}]}}")
        List<Contract> getContractsByGovernmentUsername(String username);
}
```

Listing 3. Pretraga ugovora po nazivu vlade koristeci @Query anotaciju

```
{
  "query": {
   "bool": {
    "must": [
     {"query": {"govermentFirstName": "first"}},
     {"query ": {"govermentLastName ": "last"}}
   ]
   }
  }
}
```

```
{
  "query": {
   "bool": {
    "should": [
     {"query": {"govermentFirstName": "first"}},
     {"query ": {"govermentLastName ": "last"}}
   ]
   }
  }
}
```

Listing 3. i 4. JSON zapis za pretragu po imenu i prezimenu zaposlenog (AND i OR)

```
{
  "query": {
   "match_phrase": {
    "contractContent": {
      "query": "ovaj ugovor sadrži ovu frazu"
    }
   }
  }
}
```

Listing 5. Pretraga po frazi u okviru sadržaja ugovora

2.1 Geoprostorna pretraga

Kako jedan od zahteva podrazumeva implementaciju geoprostorne pretrage tako što korisnik unosi ime grada ili adresu i radijus traženja, potrebno je u vladi čuvati i podatke o lokaciji. Za dobije tačnih koordinata putem adrese može se koristiti *Google Maps API*. Na osnovu tih koordinata kasnije se može veoma efikasno i precizno vršiti pretraga. Par numeričkih vrednosti (*latitude, longitude)*, koji se dobije konvertovanjem adrese u koordinate, čuva se u posebnom polju tipa geo_point (*GeoPoint)*.

```
 "query": {
  "bool": {
   "must": {
    "match_all": {}
   },
   "filter": {
    "geo_distance": {
     "distance": "40km",
     "government.adress": {
      "lat": 45.26,
      "lon": 19.83
     }
    }
   }
 }
```

Listing 6. predstavlja primer geoprostorne pretrage ugovora u radijusu od 40km udaljenosti od Novog Sada.

3. Konfiguracije

3.1 Konfiguracija *ElasticSearch*

Aplikacija se oslanja na *ElasticSearch* kao servis za efikasnu pretragu sadržaja. Odabrana verzija Elasticsearcha je 7.4.0. zbog kompatibilnosti sa *SerbianAnalyzer* plugin-om. *ElasticSearch* se pokreće kao zasebna aplikacija na lokalnoj mašini na portu 9200. Ovaj port je default-ni i ne mora se dodatno konfigurisati.

Komunikacija sa serverskom stranom aplikacije moguća je pozivanjem REST API koji nudi *ElasticSearch*. Za implementaciju je odabran pristup baziran na *Spring*-ovom projektu *Spring Data ElasticSearch*. Osnovna ideja jeste mapiranje metoda definisanih kroz repozitorijum nad određenim indeksnim strukturama na konkretne pozive REST API *endpoint*-a koje pruža *ElasticSearch* aplikacija. Ukoliko je potrebno, dodatne parametre kao što su lozinke, korisnička imena i sl. moguće je konfigurisati putem application.properties fajla.

U slučaju da repozitorijum ne budu mogao da pruži sve potrebne mogućnosti i da podrži sve potrebne upite, po potrebi se može koristiti i *ElasticSearchRestTemplate*.

3.2 Konfiguracija SerbianAnalyzer Plugin-a

U okviru projekta je neophodno podržati pretprocesiranje ulaznog teksta napisanog na srpskom jeziku. Zbog specifičnosti jezika i određenih slova (ć, č, š, ž, đ), potrebno je preuzeti i upotrebiti navedeni plugin kako bi se omogućila efikasna i tačna pretraga teksta. Implementacija plugin-a može se pronaći na linku https://github.com/chenejac/udd06 dok se način same integracije u projekat može detaljno ispratiti u README fajlu. Kasnije, ukoliko je potrebno koristiti ovaj plugin prilikom obrade teksta, to je potrebno eksplicitno označiti u indeksnoj strukturi (primer na listingu 1.).

3.3 Konfiguracija ELK Stack-a

ELK Stack predstavlja grupu projekata dizajniranu da korisicnima omogući efikasnu i jednostavnu pretragu, analizu i vizuelizaciju podataka, prikupljenih sa raznih izvora u različitim formatima, u realnom vremenu. Sastoji se od 3 aplikacije:

- *ElasticSearch* – aplikacija za efikasnu pretragu koja omogućava visoke performanse.
- *Logstash* – aplikacija koja omogućava rukovanje logovima, pruža podršku za dobavljanje logova iz različitih izvora, njihovu obradu i prosleđivanje na željeno skladište. Često se koristi u kombinaciji sa *Filebeat* aplikacijom koja preuzima ulogu dostavljanja logova do *Logstash* aplikacije.
- *Kibaana* – aplikacija koja podržava različite vidove vizualizacije podataka i čija je integracija sa *ElasticSearch*-om podržana bez dodatne konfiguracije. Definisanjem *Index Patterns* moguće je

preuzeti podatke skladištene u okviru *ElasticSearch*-a, koji kasnije mogu biti vizuelizovani u vidu grafikona, *chart*-ova i sl.

S obzirom na povezanost ovih aplikacija, neophodno je pažljivo izvršiti konfigurisanje i integraciju, kako se ne bi narušila njihova međusobna kompatibilnost.